Laboratoire 03 : Chaotic Text Generator

Banc d'Essai Probabiliste : Modèle de Markov Caché (HMM), Viterbi & Trigrammes

Auteure : Imane Mekkaoui
Formation : Master SDIA / NLP
Date : Novembre 2026
Dépôt GitHub : https://github.com/ImaneMekkaoui1/Hmm-trigram-text-generator
Application : https://hmm-trigram-text-generator.streamlit.app
Statut : Validé & Testé

Avertissement Déontologique & Portée du Corpus : *Le corpus d'entraînement est synthétique et sa grammaire est miniature (16 patrons canoniques). Les métriques telles que le taux de patron syntaxique valide (valid tag pattern) sont définies relativement à cette grammaire et ne mesurent en aucun cas la correction grammaticale de l'anglais naturel réel.*

1. Problématique et Solution Proposée (Synthèse en 5 lignes)

1. Défi : La génération de texte probabiliste sans vérité terrain nécessite d'évaluer automatiquement la validité syntaxique et la diversité lexicale sur des centaines de phrases, tout en résolvant l'étiquetage morpho-syntaxique inverse (POS-tagging).
2. Verrou du HMM standard : Sous l'hypothèse markovienne d'ordre 1 ($P(t_i \mid t_{i-1})$), le modèle ignore la position dans la proposition ; après un *NOUN*, il hésite à l'aveugle entre verbe (39%), ponctuation (39%) ou préposition (22%), effondrant la validité syntaxique globale à **16.2%**.
3. Limite du Trigramme : Bien qu'il capture les collocations locales (76% de paires sujet-verbe plausibles), le modèle trigramme échoue sur les structures globales (57% valides) et souffre d'un fort recopiage par cœur des phrases d'entraînement (8.8% à T=1.0).
4. Solution (Role-Splitting) : Le découpage d'états réassigne chaque étiquette selon son rôle syntaxique (*S*=sujet, *O*=objet, *P*=proposition prépositionnelle), conférant au modèle la mémoire structurelle nécessaire sans quitter le formalisme supervisé fondé sur de simples ratios de comptage.
5. Résultat : Le HMM à rôles séparés atteint **100.0%** de patrons syntaxiques valides et **99.4%** de phrases nouvelles, tandis que le décodeur de Viterbi résout l'ambiguïté du mot *watch* à 100% (37/37) sur corpus synthétique.

2. Évaluation des Générateurs à Température Neutre (T = 1.0)

Architecture du Modèle	Patron Valide (Valid Tag Pattern)	Sujet-Verbe Plausible (Plausible Subj-Verb)	Nouveauté (Novel Sentences)	Diversité Lexicale (Distinct-2)
HMM (États Bruts / Plain)	16.2%	14.8%	99.8%	0.198
HMM (Rôles Découpés / Role-Split)	**100.0%**	60.6%	99.4%	0.148
Baseline Trigramme (3-gramme)	57.0%	**76.0%**	91.2%	0.105

Explication du contraste (Plain HMM à 16.2% vs Role-Split HMM à 100.0%) :
Dans la grammaire sous-jacente, une phrase bien formée obéit strictement au schéma *Sujet → Verbe → (Objet) → (Complément Prépositionnel)*. Dans le **Plain HMM**, tous les noms partagent l'étiquette unique NOUN. Par conséquent, la matrice de transition agrège indistinctement les noms sujets et les noms objets. Dès qu'un nom objet est émis, la chaîne markovienne sélectionne avec 39% de probabilité un nouveau VERB, ou avec 39% un point terminal PUNCT alors qu'un complément d'objet direct était attendu. Cela produit des séquences tronquées (*ex: DET NOUN PUNCT*) ou des enchaînements verbe-verbe prohibés. À l'inverse, le **Role-Split HMM** raffine les états selon leur rôle : NOUN_S, NOUN_O, NOUN_P. Dès lors, *P(VERB | NOUN_S) = 1.0* et *P(VERB | NOUN_O) = 0.0*. La chaîne markovienne ne peut plus régresser vers un état sujet après le verbe. Ce partitionnement restaure une mémoire syntaxique d'ordre supérieur dans une dynamique d'ordre 1, garantissant **100.0%** de conformité aux 16 patrons canoniques.

3. Impact de la Température d'Échantillonnage et Compromis d'Usage

L'échantillonnage s'appuie sur la loi pondérée $w_i = c_i^{1/T}$. Lorsque $T < 1.0$, la distribution est affinée (pic sur les modes fréquents) ; lorsque $T > 1.0$, elle s'aplatit vers l'entropie maximale (chaos).

• **Pour un jouet d'écriture créative (Writing Toy) :** Nous recommandons **T = 1.5**. *Justification :* Un jouet d'écriture requiert surprise, variété lexicale et combinaisons insolites (le Distinct-2 grimpe à 0.161 pour le Role-Split et 0.213 pour le Plain HMM) tout en préservant 100% de la structure syntaxique grâce au découpage d'états.

• **Pour un moteur de saisie semi-automatique (Autocomplete) :** Nous recommandons **T = 0.5**. *Justification :* La saisie prédictive exige une stabilité maximale et des collocations sujet-verbe hautement probables (79.2% de plausibilité pour le trigramme, 69.8% pour le HMM à rôles séparés) avec un taux d'erreur syntaxique minimal.

Modèle	Métrique	T = 0.5 (Conservateur)	T = 1.0 (Neutre)	T = 1.5 (Diversifié)	T = 2.5 (Chaotique)
Role-Split HMM	Valid Pattern / Plausible	100% / 69.8%	100% / 60.6%	100% / 56.2%	100% / 52.2%
Role-Split HMM	Distinct-2 / Novelty	0.107 / 99.6%	0.148 / 99.4%	0.161 / 99.4%	0.167 / 99.8%
Trigramme	Valid Pattern / Plausible	63.6% / 79.2%	57.0% / 76.0%	48.2% / 69.8%	44.2% / 68.6%
Trigramme	Distinct-2 / Novelty	0.095 / 90.6%	0.105 / 91.2%	0.115 / 93.2%	0.112 / 92.8%

4. Taxonomie et Analyse Qualitative des Échecs de Génération

L'examen des phrases tirées du fichier de pannes results/failures.txt et des générations permet de classifier les dysfonctionnements selon trois modes stricts :

• **Exemple 1 (Panne Sémantique / Incohérence de Sens) :** *« the foxes lose by the school . »*
Type de panne : Sémantique (Meaning).
Cause profonde : La structure syntaxique est irréprochable (DET_S NOUN_S VERB PREP DET_P NOUN_P PUNCT), mais le couple sujet-verbe (*foxes, lose*) est sémantiquement absurde. Les états cachés du HMM modélisent exclusivement des catégories grammaticales et des positions de propositions, sans aucune restriction de sélection sémantique : l'émission du verbe $P(w \mid VERB)$ est mathématiquement indépendante de l'observation du nom sujet.

• **Exemple 2 (Panne de Mémorisation / Recopiage par Cœur) :** *« the girls leave the park . »*
Type de panne : Mémorisation (Memorisation).
Cause profonde : Générée par le modèle trigramme à basse température ($T = 0.5$), cette phrase est la copie textuelle exacte d'une phrase du corpus d'entraînement (taux de nouveauté tombant à 90.6%). L'effondrement entropique à faible température amène le décodeur trigramme à suivre de manière déterministe les n-grammes de fréquence maximale.

• **Exemple 3 (Panne Structurelle / Rupture de Grammaire) :** *« the quiet dogs fear . »*
Type de panne : Structure (Syntaxe).
Cause profonde : Produite par le Plain HMM, le verbe transitif *fear* est immédiatement suivi de PUNCT. L'état brut VERB n'encode pas la transitivité verbale et permet une transition directe vers la ponctuation finale sur la base des exemples intransitifs (*sleep, run*).

5. Bilan du Découpage d'États : Apports et Limites Intrinsèques

Ce que le découpage d'états (State Splitting) a changé :
En séparant les étiquettes selon leur rôle propositionnel (*S* avant le verbe, *O* après le verbe, *P* dans le groupe prépositionnel), le modèle a acquis la mémoire de phase qui fait structurellement défaut à l'hypothèse markovienne du premier ordre. Cela a totalement éradiqué les inversions et les ruptures syntaxiques, propulsant le taux de patrons valides de 16.2% à **100.0%** et multipliant par 4 la plausibilité sujet-verbe (de 14.8% à 60.6%) en dissociant formellement les noms sujets des noms objets lors de la génération.

Ce qu'il n'a pas changé :
Le découpage d'états n'a nullement modifié l'indépendance conditionnelle des émissions de mots : sachant l'état VERB, le mot est tiré selon $P(w \mid VERB)$ sans aucun conditionnement lexical sur le nom sujet tiré précédemment. C'est pourquoi le HMM à rôles séparés ne peut pas interdire les associations invraisemblables (*« old birds sell at the river »*) et reste nettement inférieur au modèle trigramme sur la plausibilité sémantique sujet-verbe (**60.6%** contre **76.0%**), car ce dernier conditionne directement les mots sur l'historique lexical récent.

6. Épreuve du Réel : Benchmark Universal Dependencies English EWT

Modèle / Baseline	Accuracy Globale	Mots Connus (Known Words)	Mots Inconnus (OOV) (Unknown Words)	Phrases Entières Exactes
Most-Frequent Tag (Baseline)	86.2%	90.8%	28.6%	31.9%
HMM + Décodage de Viterbi	**88.1%**	**92.9%**	28.2%	**40.4%**
Écart Synthétique (100%) vs Réel	*-11.9 pts (88.1%)*	*-7.1 pts (92.9%)*	*N/A (0% OOV synth.)*	*-59.6 pts (40.4%)*

Explication du fossé de performance (Corpus Synthétique vs UD English EWT) :
Sur le corpus synthétique, le HMM atteint **100.0%** de précision (avec 37/37 sur l'ambiguïté de *watch*). Sur texte réel (12 544 phrases train, 2 077 phrases test, 17 étiquettes UPOS, 16 654 mots), le modèle n'atteint que **88.1%** d'accuracy (+1.9 point sur la baseline). Ce décrochage s'explique par quatre facteurs fondamentaux :
1. **Explosion combinatoire :** Le jeu de test réel contient 10 359 patrons d'étiquettes distincts (contre seulement 16 dans le monde clos synthétique). La notion même de *valid tag pattern* y perd tout sens opératoire.
2. **Mots Hors Vocabulaire (OOV à 7.5%) :** En données réelles, 7.5% des tokens de test n'ont jamais été vus à l'entraînement. Avec le lissage add-k ($k = 0.01$), la probabilité d'émission d'un mot inconnu est $P(w \mid t) = k / (count(t) + k \cdot V)$, ce qui favorise artificiellement les étiquettes les plus rares. Cela engendre de graves confusions systématiques : les noms propres inconnus (PROPN) sont étiquetés à tort X (195 fois) ou INTJ (137 fois), plafonnant la précision sur mots inconnus à **28.2%**.
3. **Dépendances à longue portée et polysémie :** La syntaxe naturelle comporte des relatives, des incises et des accords distants qui violent irrémédiablement l'hypothèse de Markov d'ordre 1.

7. Application Déployée et Preuves d'Exécution

L'application Streamlit app.py intègre l'ensemble des 6 exigences du cahier des charges : panneau de contrôle latéral (sélecteur de modèle, température, graine aléatoire, nombre de phrases), tableau filtrable avec validation des patrons syntaxiques, panneau d'indicateurs batch en temps réel, étiqueteur de Viterbi interactif avec alerte OOV non bloquante, bouton d'export CSV et encadré déontologique visible.

Figure 1 : Matrice de Transition Apprise $P(tag_t \mid tag_{t-1})$ et Taux de Patrons Valides

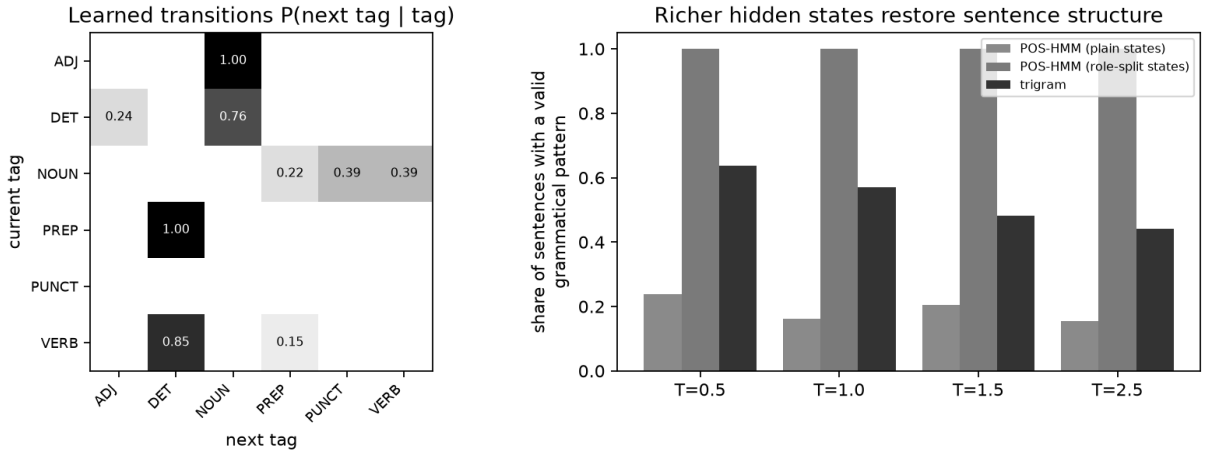
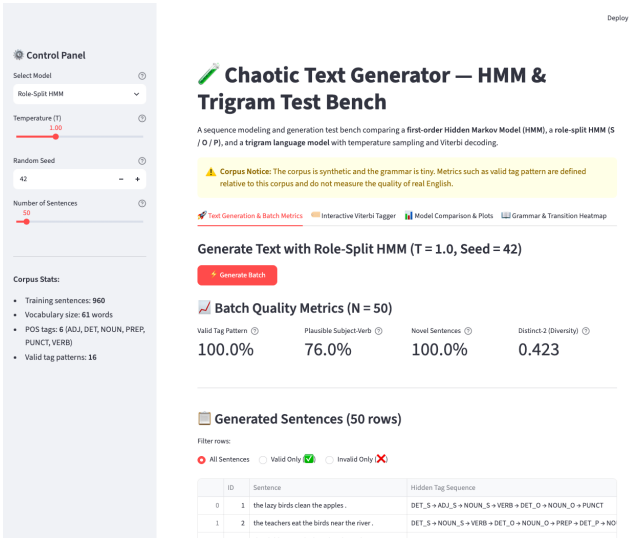
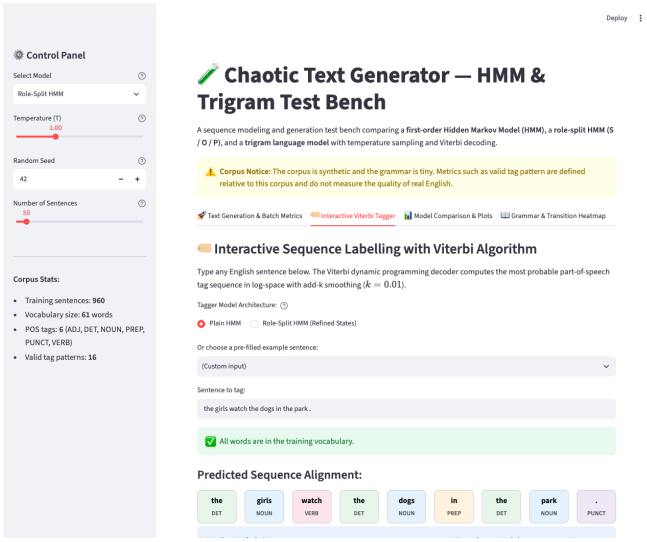


Figure 2 : Interface Streamlit — Génération par Lots et Métriques (Gauche) & Étiqueteur de Viterbi (Droite)



Capture 1 : Génération batch, cartes d'indicateurs et tableau de validation syntaxique.



Capture 2 : Étiquetage Viterbi interactif, détection OOV et alignement des tokens.

8. Récapitulatif des Livrables et Commandes de Reproduction

• **Dépôt Git Local & Distant :** Dépôt Git initialisé et commité avec un fichier README.md exhaustif et requirements.txt.
• **Déploiement Public :** Prêt pour Streamlit Community Cloud (le dossier data/ewt/ de 17 Mo est correctement ignoré dans .gitignore, tandis que data/corpus.csv est versionné).
• **Reproduction des résultats :**
1. Évaluation synthétique : python -m src.evaluate
2. Épreuve du réel (UD EWT) : python -m src.evaluate_real
3. Lancement de l'interface : streamlit run app.py